Глубинное обучение
Лекция 1: Введение

Лектор: Антон Осокин

ФКН ВШЭ, 2018

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

Что такое и зачем изучать глубинное обучение?

- Про что курс?
  - Про **глубокие нейросети**
  - Архитектуры, обучение, регуляризация
  - Примеры использования
    - Компьютерное зрение
    - Обработка текстов

- Зачем это изучать?
  - Практические результаты
  - Развитая технология

Нейросети в компьютерном зрении

Классификация изображений

IMAGENET

- 1,000 object classes (categories).
- Images:
  - 1.2 M train
  - 100k test.

[Krizhevsky et al., 2012]

Обнаружение объектов

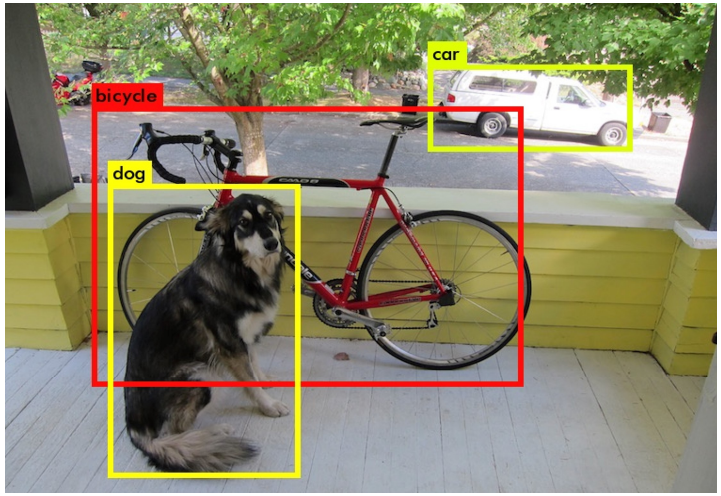

[Redmon&Farhadi, 2017]

Сегментация объектов

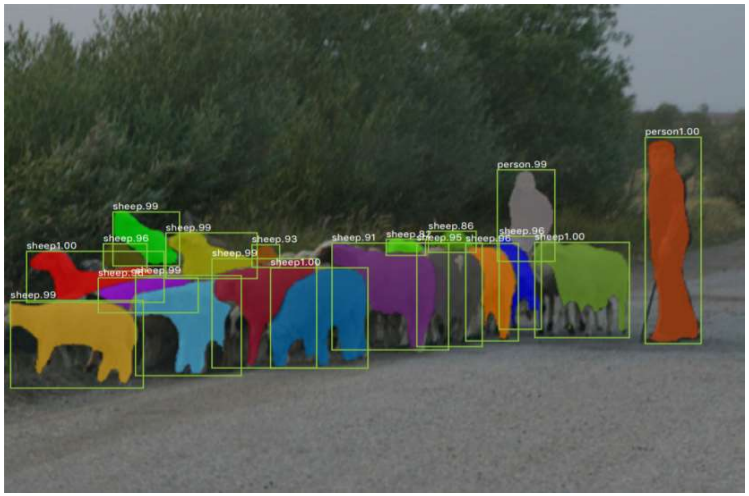

[He et al., 2017]

Нейросети для текстов

Автоматический перевод

Диалоговые системы

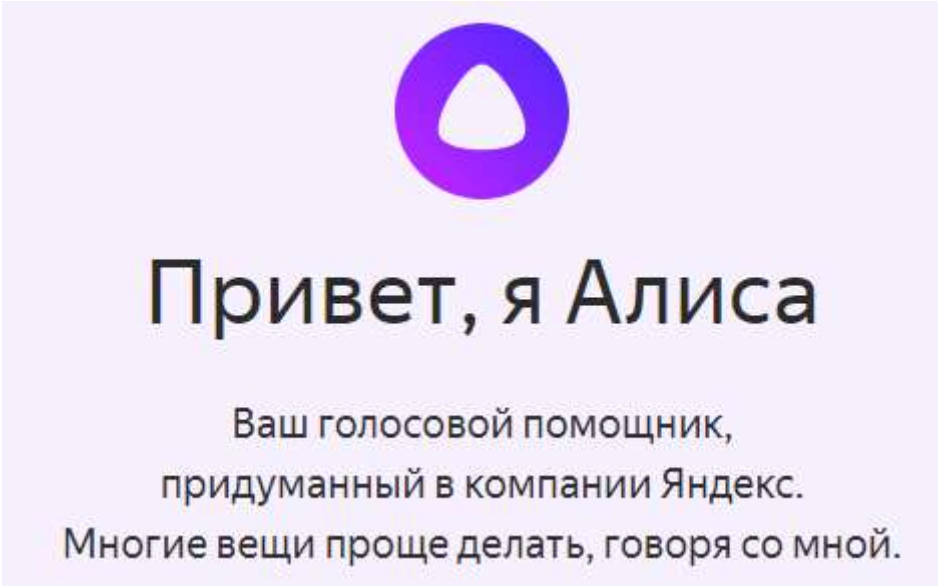

Нейросети для аудио

- Распознавание речи
- text2speech – WaveNet [van den Oord et al., 2016]

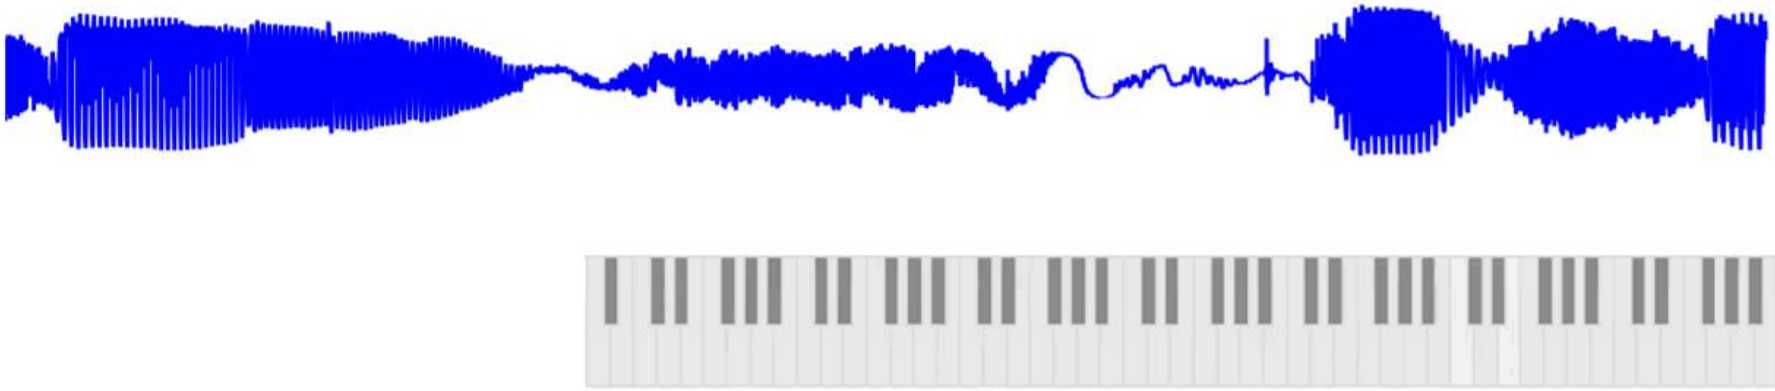

- Синтез музыки

Performance RNN was trained in TensorFlow on MIDI from piano performances. It was then ported to run in the browser using only Javascript in the deeplearn.js environment.

Игры

Atari [DeepMind, Mnih et al.,

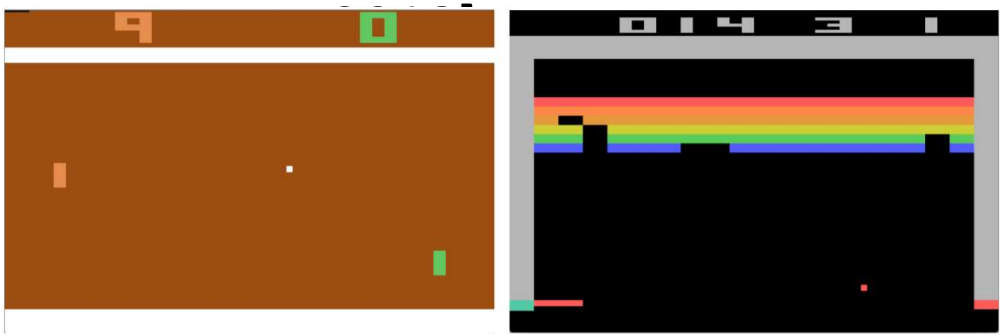

Го [DeepMind, Silver et al., 2016]

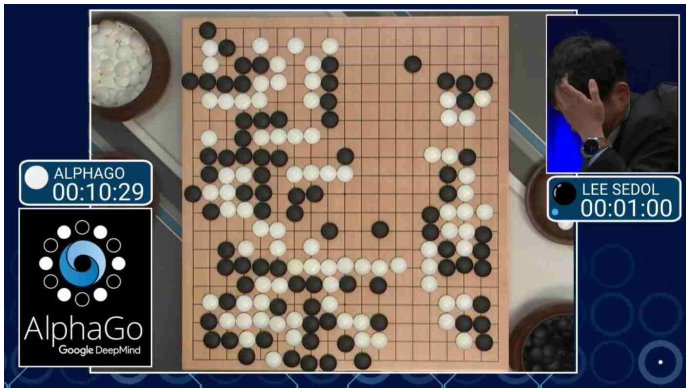

Dota2 1v1 (simplified)
[OpenAI, 2017]

План курса

- Введение
- Основные концепции
  - Механика нейросетей и backprop
  - Виды архитектур
  - Обучение и регуляризация
- Продвинутые темы
  - Применения в компьютерном зрении
  - Применения для обработки языка
  - Вероятностные модели
  - Adversarial X
  - Дифференцируемое программирование
  - Недифференцируемые модели и Deep RL
- Guest star

Важная информация

- Семинары и домашние задания
  - На каждом семинаре notebook
  - Домашнее задание = доделать материал семинара
  - pytorch со второго семинара
- Проект
  - Реализация и обучение нейросети (на GPU)
- Экзамен
  - Автоматы тем, кто сдаст домашки и проект
- Коммуникация
  - Задания: http://anytask.org/
  - E-mail курса: dl.cshse@gmail.com
    - Напишите письмо с указанием почты, ФИО, группы

Microsoft, спасибо!

Нейросети прямого распространения (feed-forward neural networks)

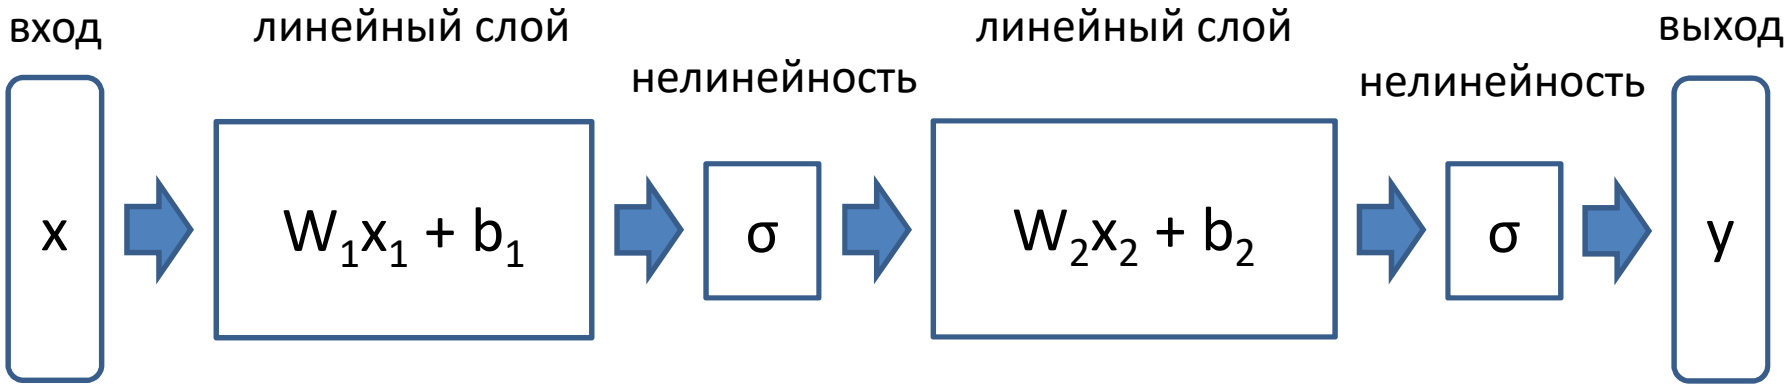

- Ориентированный граф вычислений
  - Вершины – переменные, нейроны [Rosenblatt, 1958]
  - Рёбра обозначают зависимости
  - Слой = операция, вычисляющая переменные
  - Переменные: входы (данные), выходы, параметры, внутренние
  - Слои: линейные (+ conv), активации (sigmoid, relu) и др.

Задача приближения функции (обучение с учителем)

- Вход: объекты $x_1, \dots, x_N \in \mathbb{R}^d$, ответы $y_1, \dots, y_N \in \mathbb{Y}$
  - Классификация: $\mathbb{Y} = \{1, \dots, K\}$
  - Регрессия: $\mathbb{Y} = \mathbb{R}$
- Семейство функций – нейросети f(x, θ)
  - Параметры θ линейного слоя (Wx + b): W , b (weights, biases)
- Задача – настроить параметры по выборке
- Функция потерь $\ell(f(x, \theta), y)$
  - Регрессия: $\ell(f(x, \theta), y) = (f(x, \theta) - y)^2$
  - Классификация: $\ell(f(x, \theta), y) = -\log\left(\frac{\exp f_y(x, \theta)}{\sum_{s=1}^{K} \exp f_s(x, \theta)}\right)$

Задача приближения функции (обучение с учителем)

- Вход: объекты $x_1, \dots, x_N \in \mathbb{R}^d$, ответы $y_1, \dots, y_N \in \mathbb{Y}$
  - Классификация: $\mathbb{Y} = \{1, \dots, K\}$
  - Регрессия: $\mathbb{Y} = \mathbb{R}$
- Семейство функций – нейросети f(x, θ)
  - Параметры θ линейного слоя (Wx + b): W , b (weights, biases)
- Задача – настроить параметры по выборке
- Функция потерь $\ell(f(x, \theta), y)$
- Задача обучения: $\min_\theta \mathbb{E}_{(x,y)\sim\mathcal{D}} \ell(f(x, \theta), y)$
- Регуляризованный эмпирический риск

$$\min_\theta \frac{1}{N} \sum_{i=1}^{N} \ell(f(x_i, \theta), y_i) + \mathcal{R}(\theta)$$

Обучение нейросети

- Регуляризованный эмпирический риск

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \ell(f(x_i, \theta), y_i) + \mathcal{R}(\theta)$$

- Задача оптимизации – сложная (не выпуклая)
- Обычно функция дифференцируема
- Стохастическая оптимизация первого порядка
  - Stochastic gradient descent (SGD)

$$\theta_{t+1} \leftarrow \theta_t - \gamma \left(\nabla_\theta \left[\ell(f(x_i, \theta_t), y_i) + \mathcal{R}(\theta_t) \right] \right)$$

  - Вычисление градиента по параметрам – back-propagation (метод обратного распространения ошибки)

[Rumelhart&McClelland, 1986]

Back-propagation

[Rumelhart&McClelland, 1986]

- Вход: x_i, y_i, параметры θ
- Найти градиент по параметрам нейросети
- Основная идея – производная сложной функции

$$\nabla_\theta f(\theta, g(\theta), h(\theta)) = \frac{\partial f}{\partial \theta} + \frac{\partial f}{\partial g}\nabla_\theta g(\theta) + \frac{\partial f}{\partial h}\nabla_\theta h(\theta)$$

- Автоматическое дифференцирование =

  построение полных производных на основе слоев
- Слой $h(x, \theta)$ – абстракция, поддерживающая операции
  - проход вперёд – вычисление $h(x, \theta)$ при известных x и θ
  - проход назад – вычисление $\nabla_x h(x, \theta)$ и $\nabla_\theta h(x, \theta)$ при известных x, θ, ∇_h

Обычно $\nabla_h = \frac{d}{dh}\ell(f(x, \theta), y)$ – это градиент потерь по выхода

Back-propagation

[Rumelhart&McClelland, 1986]

- Вход: x_i, y_i, параметры W_1, b_1, W_2, b_2
- Найти градиент по параметрам нейросети

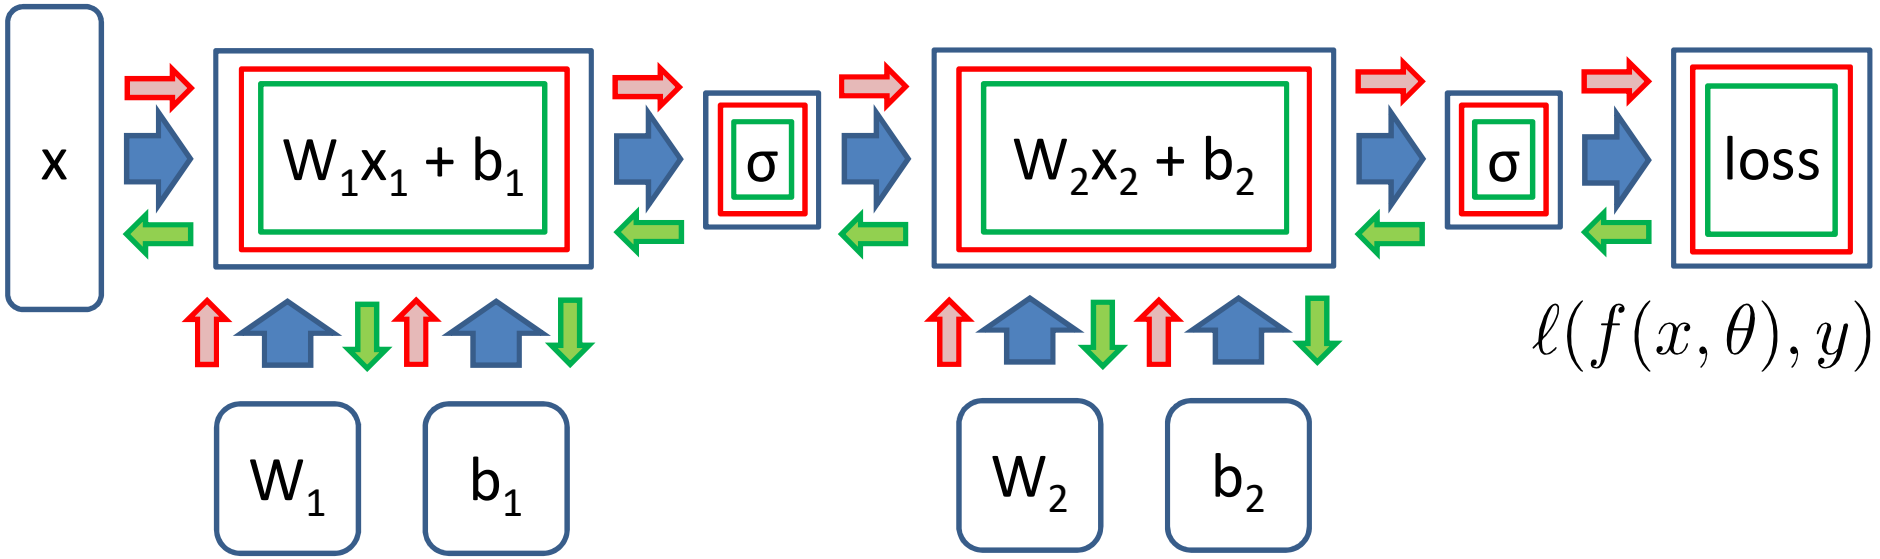

1. Проход вперёд (вычисление слоёв и функции потерь)
2. Проход назад (вычисление градиентов)

Дифференцирование одного слоя

- Слой $h(x, \theta)$ – абстракция, поддерживающая операции
  - проход вперёд – вычисление $h(x, \theta)$ при известных x и θ
  - проход назад – вычисление $\nabla_x h(x, \theta)$ и $\nabla_\theta h(x, \theta)$ при известных x, θ, ∇_h
- Функция потерь $\ell(f, y)$
  - Выходного градиента нет (можно считать константой 1)
  - Частные производные по выходам нейросети $\frac{\partial \ell}{\partial f}$
- Функции активации $\sigma(x) = \frac{1}{1+\exp(-x)}$, $\mathrm{ReLu}(x) = \begin{cases} 0, x \leq 0, \\ x, x > 0 \end{cases}$
  - Поэлементное дифференцирование

$$\frac{\partial \sigma(x)}{\partial x} = \sigma(x)(1-\sigma(x)) \quad \frac{\partial \mathrm{ReLu}(x)}{\partial x} = \begin{cases} 0, x \leq 0, \\ 1, x > 0 \end{cases}$$

  - Полная производная – поэлементное произведение

$$\nabla_x = \frac{\partial h(x)}{\partial x} \odot \nabla_h$$

Дифференцирование линейного слоя

- Слой $h(x, \theta)$ – абстракция, поддерживающая операции
  - проход вперёд – вычисление $h(x, \theta)$ при известных x и θ
  - проход назад – вычисление $\nabla_x h(x, \theta)$ и $\nabla_\theta h(x, \theta)$ при известных x, θ, ∇_h
- Линейный слой $h(x, W) = Wx$
  - Известны x и ∇_h
  - Найти ∇_x

$$\begin{pmatrix} h_1 \\ h_2 \end{pmatrix} = \begin{pmatrix} w_{11} w_{12} w_{13} \\ w_{21} w_{22} w_{23} \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \\ x3 \end{pmatrix} = \begin{pmatrix} w_{11}x_1 + w_{12}x_2 + w_{13}x_3 \\ w_{21}x_1 + w_{22}x_2 + w_{23}x_3 \end{pmatrix}$$

$$\nabla_{x_1} = \nabla_{h_1} \frac{\partial h_1}{\partial x_1} + \nabla_{h_2} \frac{\partial h_2}{\partial x_1} = \begin{pmatrix} w_{11} w_{21} \end{pmatrix} \begin{pmatrix} \nabla_{h_1} \\ \nabla_{h_2} \end{pmatrix} \Rightarrow \nabla_x = W^T \nabla_h$$

$$\nabla_{w_{21}} = \nabla_{h_1} \frac{\partial h_1}{\partial w_{21}} + \nabla_{h_2} \frac{\partial h_2}{\partial w_{21}} = \nabla_{h_2} x_1 \Rightarrow \nabla_W = \nabla_h x^T$$

Тестирование дифференцирования

Ошибки в вычислении градиентов встречаются часто!
Очень сложно находить!
Система может работать, но на 5-10% хуже

Unit test: конечные разности (finite differences)

$$\nabla_\theta h(x,\theta) \approx \frac{h(x,\theta+\varepsilon)-h(x,\theta-\varepsilon)}{2\varepsilon}$$

Как выбрать ε?

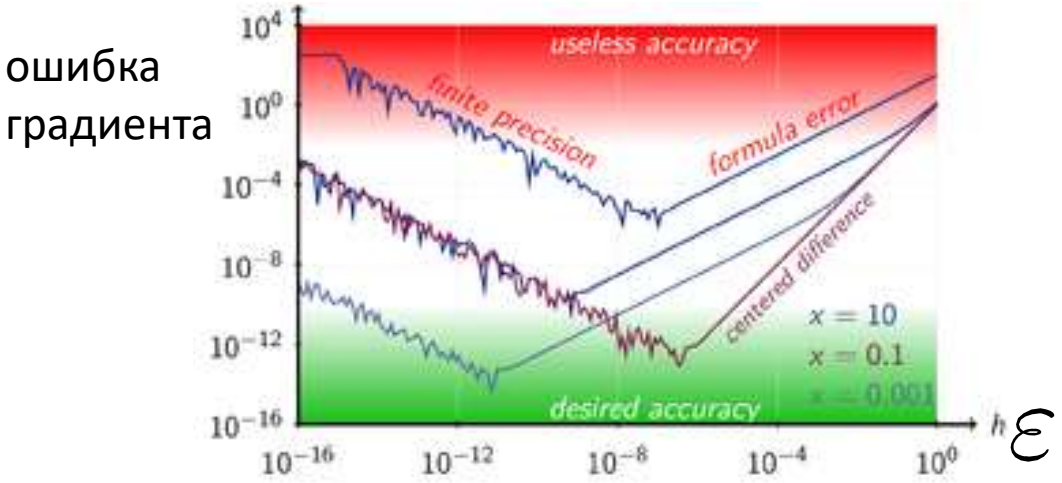

график из википедии

Нейросети прямого распространения = универсальные аппроксиматоры

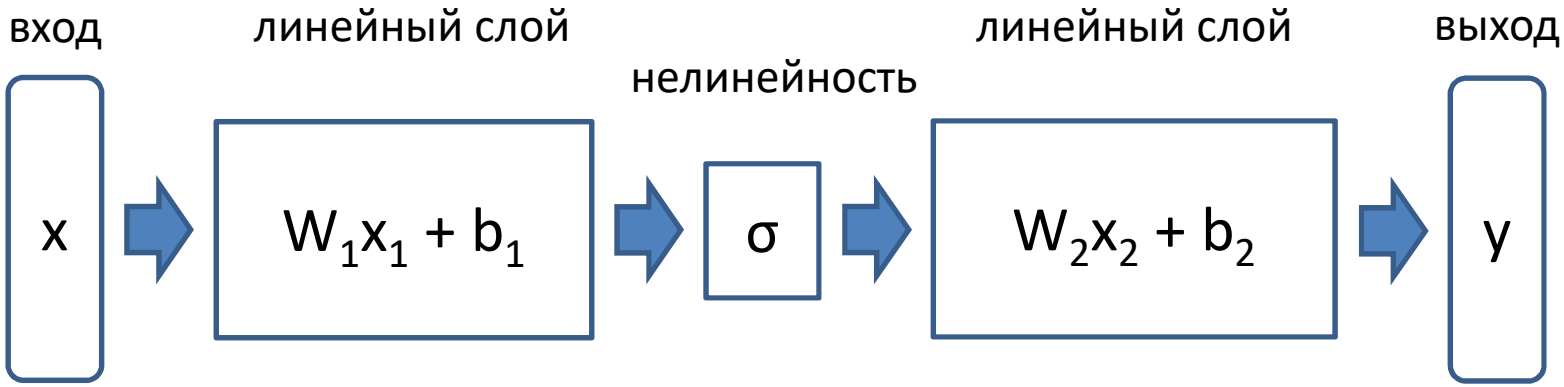

Теорема об универсальной аппроксимации [Cybenko, 1989]

Любую функцию можно с любой точностью приблизить нейросетью глубины 2 с сигмоидной функцией активации

Задача решена? Строим AI?

Проблемы нейросетей

- Для аппроксимации может понадобиться слишком много узлов
  - Большая глубина даёт выразительность меньшим числом узлов
- Переобучение, слишком много параметров
  - Переиспользование параметров
  - Использование структуры данных (архитектуры)
  - Регуляризация
- Нестабильное обучение, плохие решения
  - Методы оптимизации, архитектуры
- Очень большое время обучения!
  - Эффективные алгоритмы и реализации
  - Hardware: GPU, кластеры, кластеры GPU, TPU, etc.

Где взять данные?

Проблема: для обучения нужно много размеченных данных!

Большинство прорывов связаны с обучением с учителем на больших данных!

Варианты:

1. Размечать ☺ (Amazon MTurk, Яндекс.Толока)
2. Использовать разметку на смежных данных
   - Нейросети позволяют выучивать полезные представления!
   - Domain adaptation
3. Обучение без учителя работает хуже ☹
4. Использовать более слабые виды учителя (weak supervision)
   - Reinforcement learning (обучение с подкреплением)
   - Semi-supervised
5. **Self-supervision**: найти разметку в самих данных!

Пример self-supervision: автокодировщик

Модель для восстановление данных через bottleneck

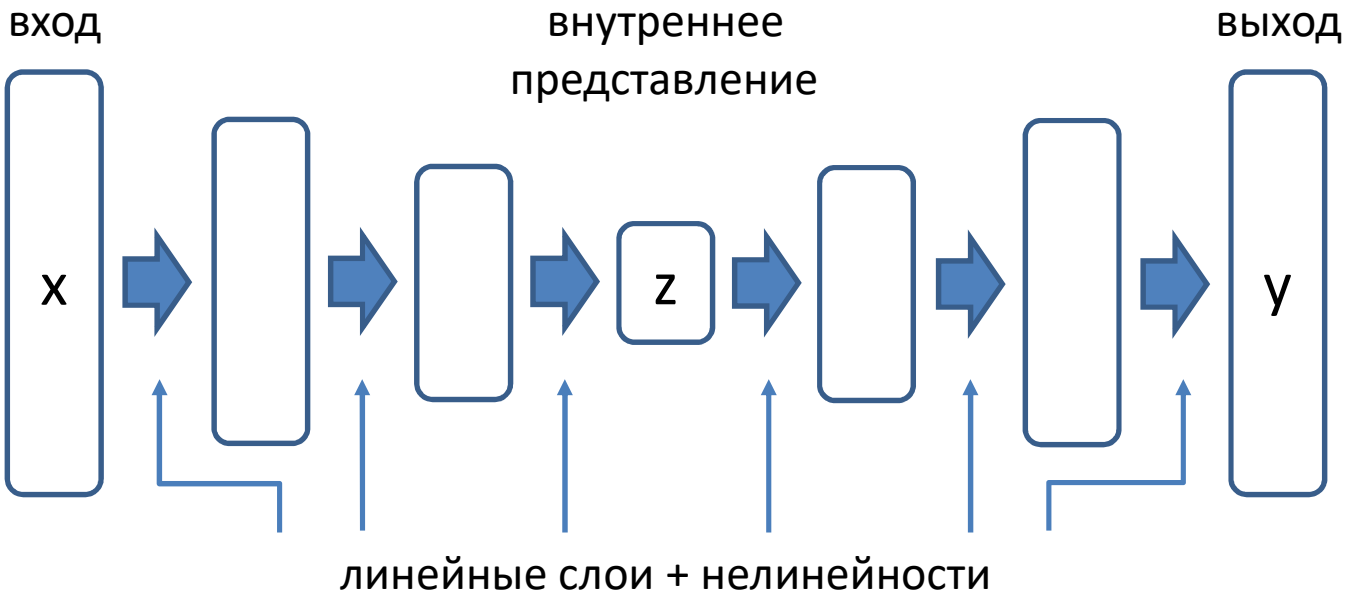

Обучение – восстановление входа $(x-y)^2$

z – внутреннее представление, которое можно использовать

Экскурс в историю нейросетей (hype cycles)

- 50-е – 60-е: Connectionism, модель нейрона [Rosenblatt, 1958]
  - Важная задача – автоматический перевод с русского
    - Проблема учёта контекста:

      the spirit is willing but the flesh is weak -> Русский ->

      the vodka is good but the meat is rotten
  - 1966: переводчики-люди дешевле и лучше компьютеров
  - 1969: Perceptrons [Minsky&Papert]
    - Однослойная нейросеть не может представить XOR
    - Не достаточно вычислительной мощности
  - 70-е: провал проектов

    (перевод, голосовые команды, автоматический танк)

Экскурс в историю нейросетей (hype cycles)

- 50-е – 60-е: Connectionism, модель нейрона
- 70-е: AI winter
  - Разочарование в AI, сокращение финансирования
- 80-е: возобновление интереса, AI hype
  - AI hype вокруг экспертных систем (коллапс в начале 90-х)
  - Backpropagation [Rumelhart&McClelland, 1986]
- 90-е – 00-е: AI winter, интерес к линейным моделям
  - Теоретически обоснованные модели с гарантиями
  - Распространение SVM [Cortes&Vapnik, 1995]
  - Распространение графических моделей

Экскурс в историю нейросетей (hype cycles)

- 50-е – 60-е: Connectionism, модель нейрона
- 70-е: AI winter: сокращение финансирования
- 80-е: возобновление интереса, AI hype
- 90-е – 00-е: AI winter, интерес к линейным моделям

- 1997: LSTM [Hochreiter&Schmidhuber]
- 1998: ConvNets распознают символы [LeCun et al.]
- 2006: Deep Boltzmann Machines [Hinton&Salakhutdinov]
- 2007: NVIDIA выпускает CUDA
- 2009-2010: успехи в распознавании речи
- 2012: ConvNets выигрывает ImageNet [Krizhevsky et al.]
- 2013-… : AI hype