

Глубинное обучение

Лекция 7: Оптимизация против нейросетей или Adversarial X

Лектор: Антон Осокин

ФКН ВШЭ, 2018



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ


План лекции

- Нераспознаваемые выходы (adversarial examples)
 - Примеры, причины, следствия
 - Способы построения и борьбы
- Адаптация к данным (domain adaptation)
 - Что это? Зачем?
 - Простейшие методы
- Нейросети как функции потерь
 - GANs

Adversarial examples

[Szegedy et al., 2013]

- Невидимые глазу изменения меняют результат сети!



правильная
классификация

шум

«ostrich»

Adversarial examples for text!

[Liang et al., 2017]

- Изменения текста (дискретные) меняют результат сети!
 - Удаления и вставки текста (настоящий текст и опечатки)

The Old Harbor Reservation Parkways are three *historie* roads in the Old Harbor area of Boston. *Some exhibitions of Navy aircrafts were often held here.* They are part of the Boston parkway system designed by Frederick Law Olmsted. They include all of William J. Day Boulevard running from *Castle* Island to Kosciuszko Circle along Pleasure Bay and the Old Harbor shore. The part of Columbia Road from its northeastern end at Farragut Road west to Pacuska Circle (formerly called Preble Circle). Old Harbor Reservation

83.7% Building => 88.7% Means of Transportation

Как атаковать сеть?

[Szegedy et al., 2013]

- Пусть у нас есть обученная сеть (классификация ImageNet)

- Сеть и функция потерь $J_\theta(x, l)$

- Атака оптимизацией:

$$\begin{aligned} \min_{x'} \quad & c\|\eta\| + J_\theta(x', l') \\ \text{s.t.} \quad & x' \in [0, 1]. \end{aligned}$$

- Быстрая атака знаком градиента (Fast Gradient Sign Method, FGSM)

$$x' = x - \epsilon \text{sign}(\nabla_x J(\theta, x, l'))$$

- Простые варианты защит:

- Обучение на атаках, ансамбли, дистилляция сетей


Что все это значит?

- Adversarial examples – область с большими следствиями
 - Свежий обзор: arXiv: 1712.07107 [Yuan et al., 2017]
 - NIPS 2017: Non-targeted Adversarial Attack
- Атаки обобщаются! [Papernot et al., 2016]
- Виды атак:
 - White-box vs. black-box
 - Targeted vs. non-targeted
- Другие алгоритмы ML тоже можно атаковать!

Adversarial example можно напечатать!

[Athalye et al., 2017]

- Можно строить устойчивые атаки!

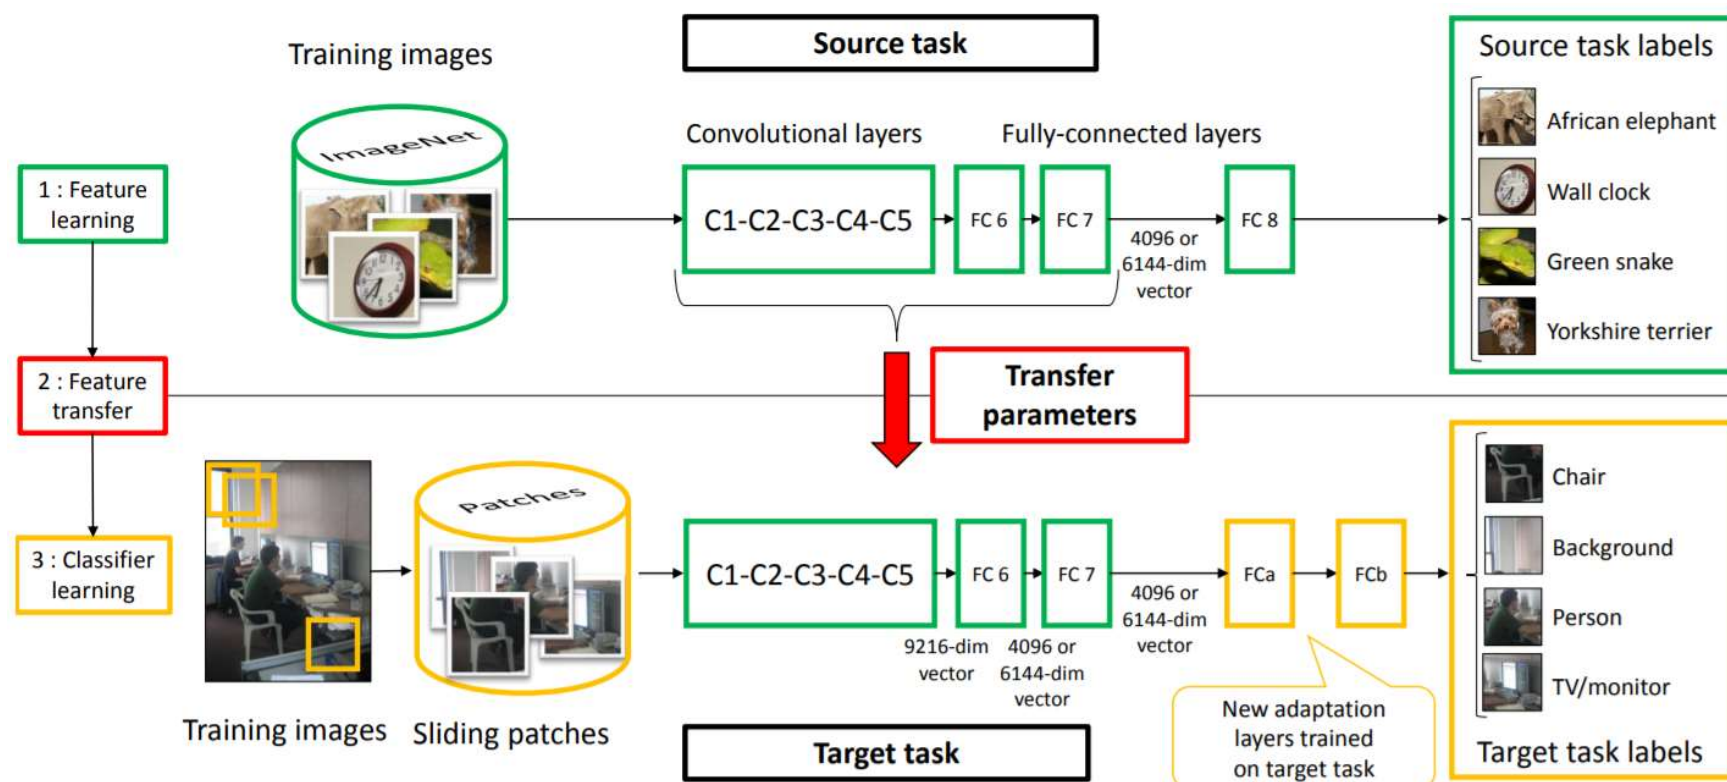


Source: <https://blog.openai.com/robust-adversarial-inputs/>

Адаптация к данным (domain adaptation)

- При обучении сетей часто сбор данных – узкое место
- Идея – обучиться на других данных и использовать эту сеть
- Формула CV 2013-н.в.:
 - Взять SOTA сеть, обученную на ImageNet
 - Откинуть голову сети, дообучиться на свою задачу

[Oquab et al., 2014]




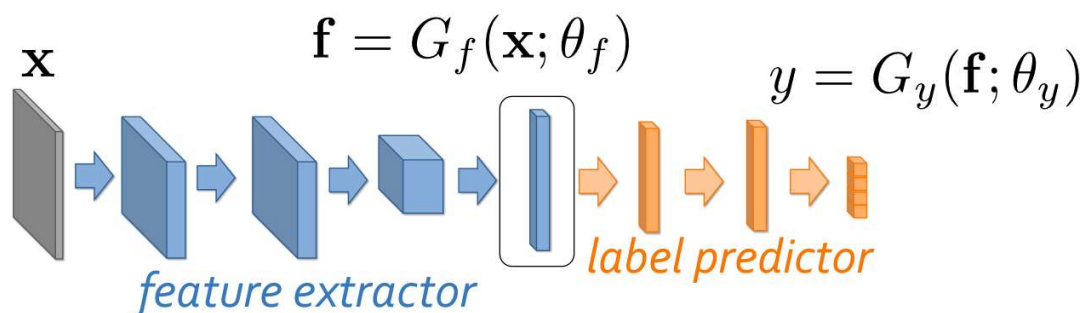
Адаптация к данным (domain adaptation)

- При обучении сетей часто сбор данных – узкое место
- Идея – обучиться на других данных и использовать эту сеть
- Формула CV 2013-н.в.:
 - Взять SOTA сеть, обученную на ImageNet
 - Откинуть голову сети, дообучиться на свою задачу
- Формула работает хуже, если данные слишком различны
 - Domain shift
- Область domain adaptation
 - Есть много размеченных данных в source domain
 - Есть много неразмеченных данных в target domain
 - Как это использовать?

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Где проявляется разница?
 - На промежуточных слоях разные значения признаков



$$S(\mathbf{f}) = \{G_f(\mathbf{x}; \theta_f) \mid \mathbf{x} \sim S(\mathbf{x})\}$$

$$T(\mathbf{f}) = \{G_f(\mathbf{x}; \theta_f) \mid \mathbf{x} \sim T(\mathbf{x})\}$$

Image credit: Victor Lempitsky

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Где проявляется разница?
 - На промежуточных слоях разные значения признаков
 - Цель – одинаковые распределения
 - Но не сломать классификацию




Image credit: Victor Lempitsky

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Идея – использовать классификатор доменов

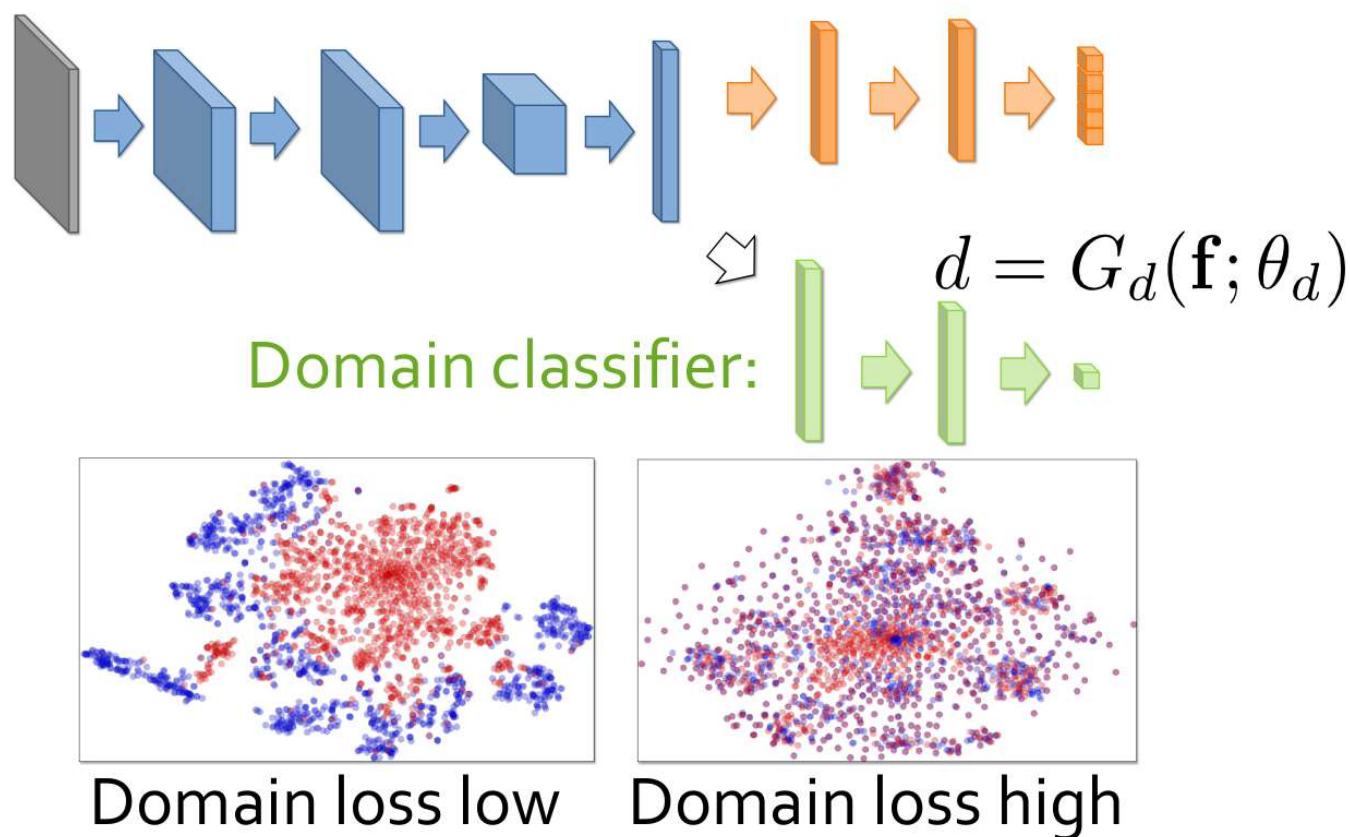


Image credit: Victor Lempitsky

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Идея – использовать классификатор доменов
- ~~• Совместное обучение классификаторов?~~

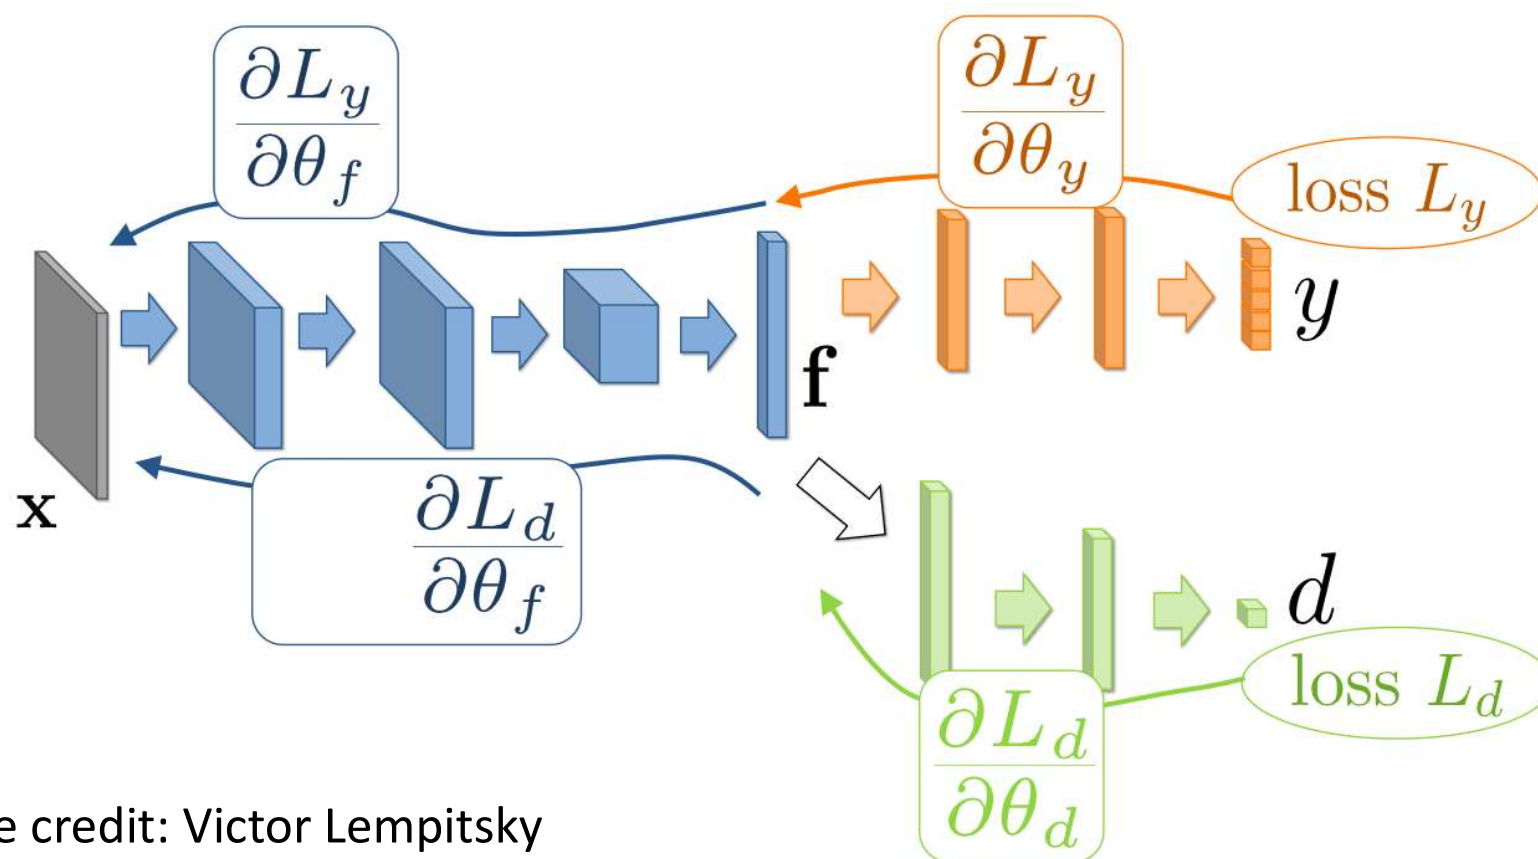


Image credit: Victor Lempitsky

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Идея – использовать классификатор доменов
- ~~Совместное обучение классификаторов?~~
- Нужно инвертировать градиент!

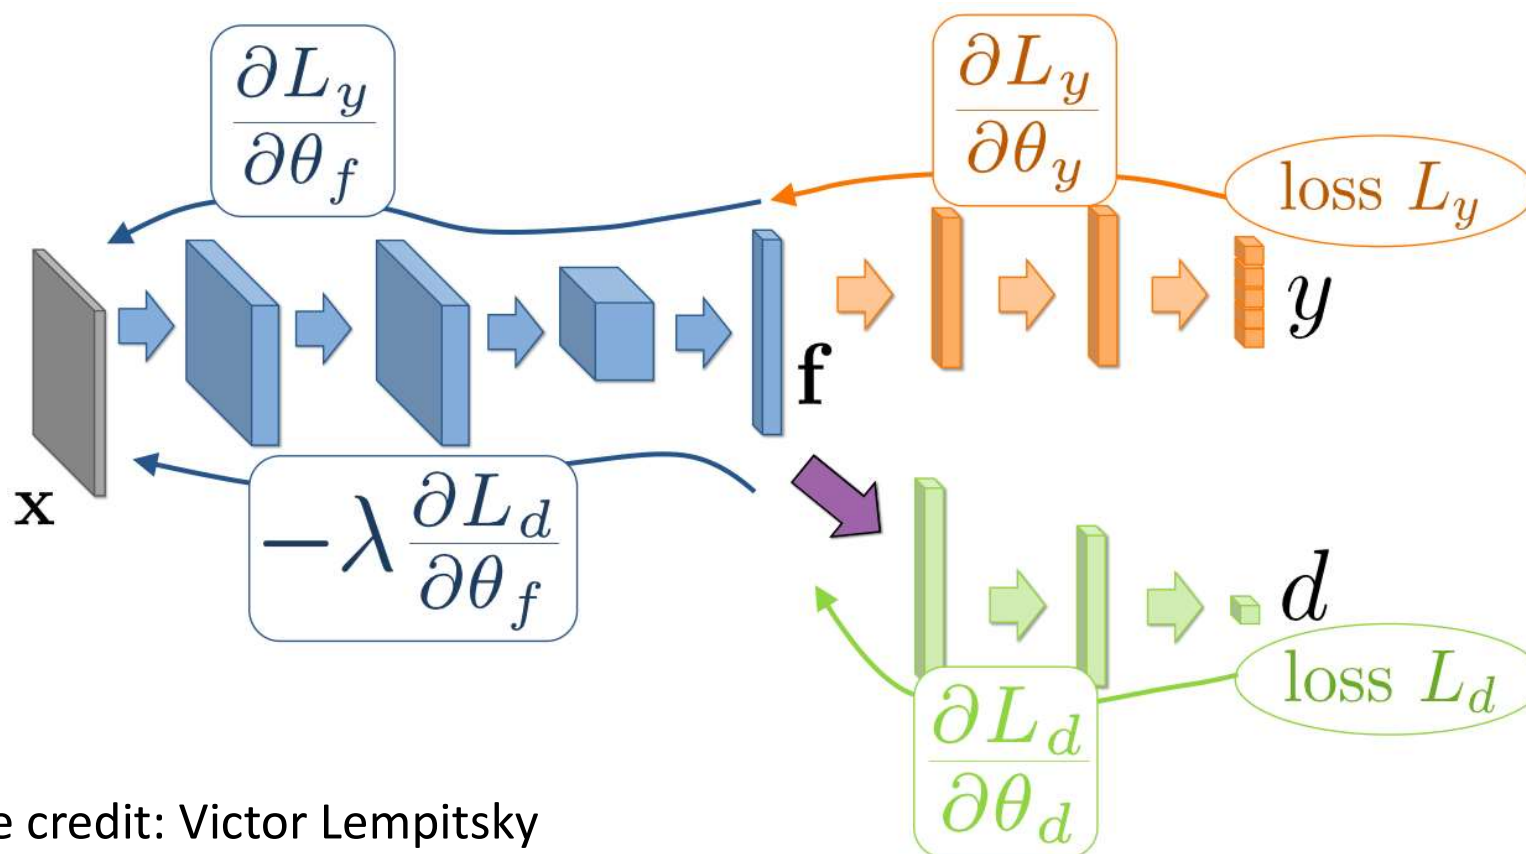


Image credit: Victor Lempitsky

Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Идея – использовать классификатор доменов
- ~~• Совместное обучение классификаторов?~~
- Нужно инвертировать градиент!
- Pytorch code:

```
class GradReverse(Function):  
    def forward(self, x):  
        return x.view_as(x)  
    def backward(self, grad_output):  
        return (grad_output * -1)  
  
def grad_reverse(x):  
    return GradReverse()(x)
```

- В обычном слое сети:

```
def forward(self, x):  
    x = grad_reverse(x)
```


Как убрать разницу (domain shift)?

[Ganin&Lempitsky, 2014]

- Идея – использовать классификатор доменов

- ~~• Совместное обучение классификаторов?~~

- Нужно инвертировать градиент!

- Интерпретация через седловую точку:

$$\begin{aligned} E(\theta_f, \theta_y, \theta_d) &= \sum_{\substack{i=1..N \\ d_i=0}} L_y(G_y(G_f(\mathbf{x}_i; \theta_f); \theta_y), y_i) - \lambda \sum_{i=1..N} L_d(G_d(G_f(\mathbf{x}_i; \theta_f); \theta_d), y_i) \\ &= \sum_{\substack{i=1..N \\ d_i=0}} L_y^i(\theta_f, \theta_y) - \lambda \sum_{i=1..N} L_d^i(\theta_f, \theta_d) \end{aligned}$$

- Оптимизация:

$$(\hat{\theta}_f, \hat{\theta}_y) = \arg \min_{\theta_f, \theta_y} E(\theta_f, \theta_y, \hat{\theta}_d)$$

$$\hat{\theta}_d = \arg \max_{\theta_d} E(\hat{\theta}_f, \hat{\theta}_y, \theta_d)$$

Generative Adversarial Networks

[Goodfellow et al., 2014]

- Генеративные модели (обычно для изображений)
- Основная идея: вместо определения целевой функции (правдоподобие, ошибка реконструкции) целевая функция обучается вместе с данными
- Генератор – сеть, синтезирующая картинки из шума
- Дискриминатор – сеть, отличающая настоящие от синтезированных

Generative Adversarial Networks

[Goodfellow et al., 2014]

Две сети:

- G – генератор
- D – дискриминатор

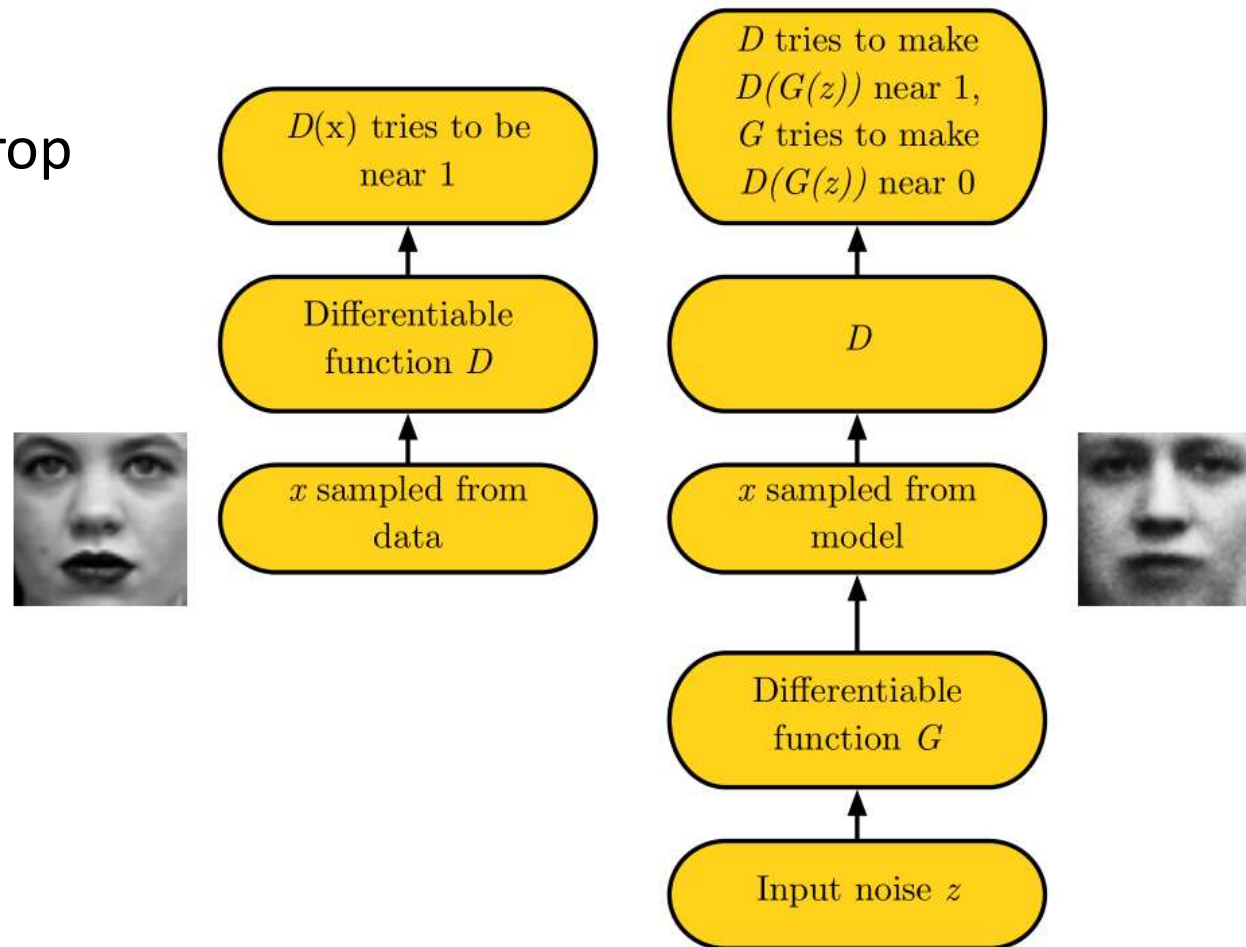


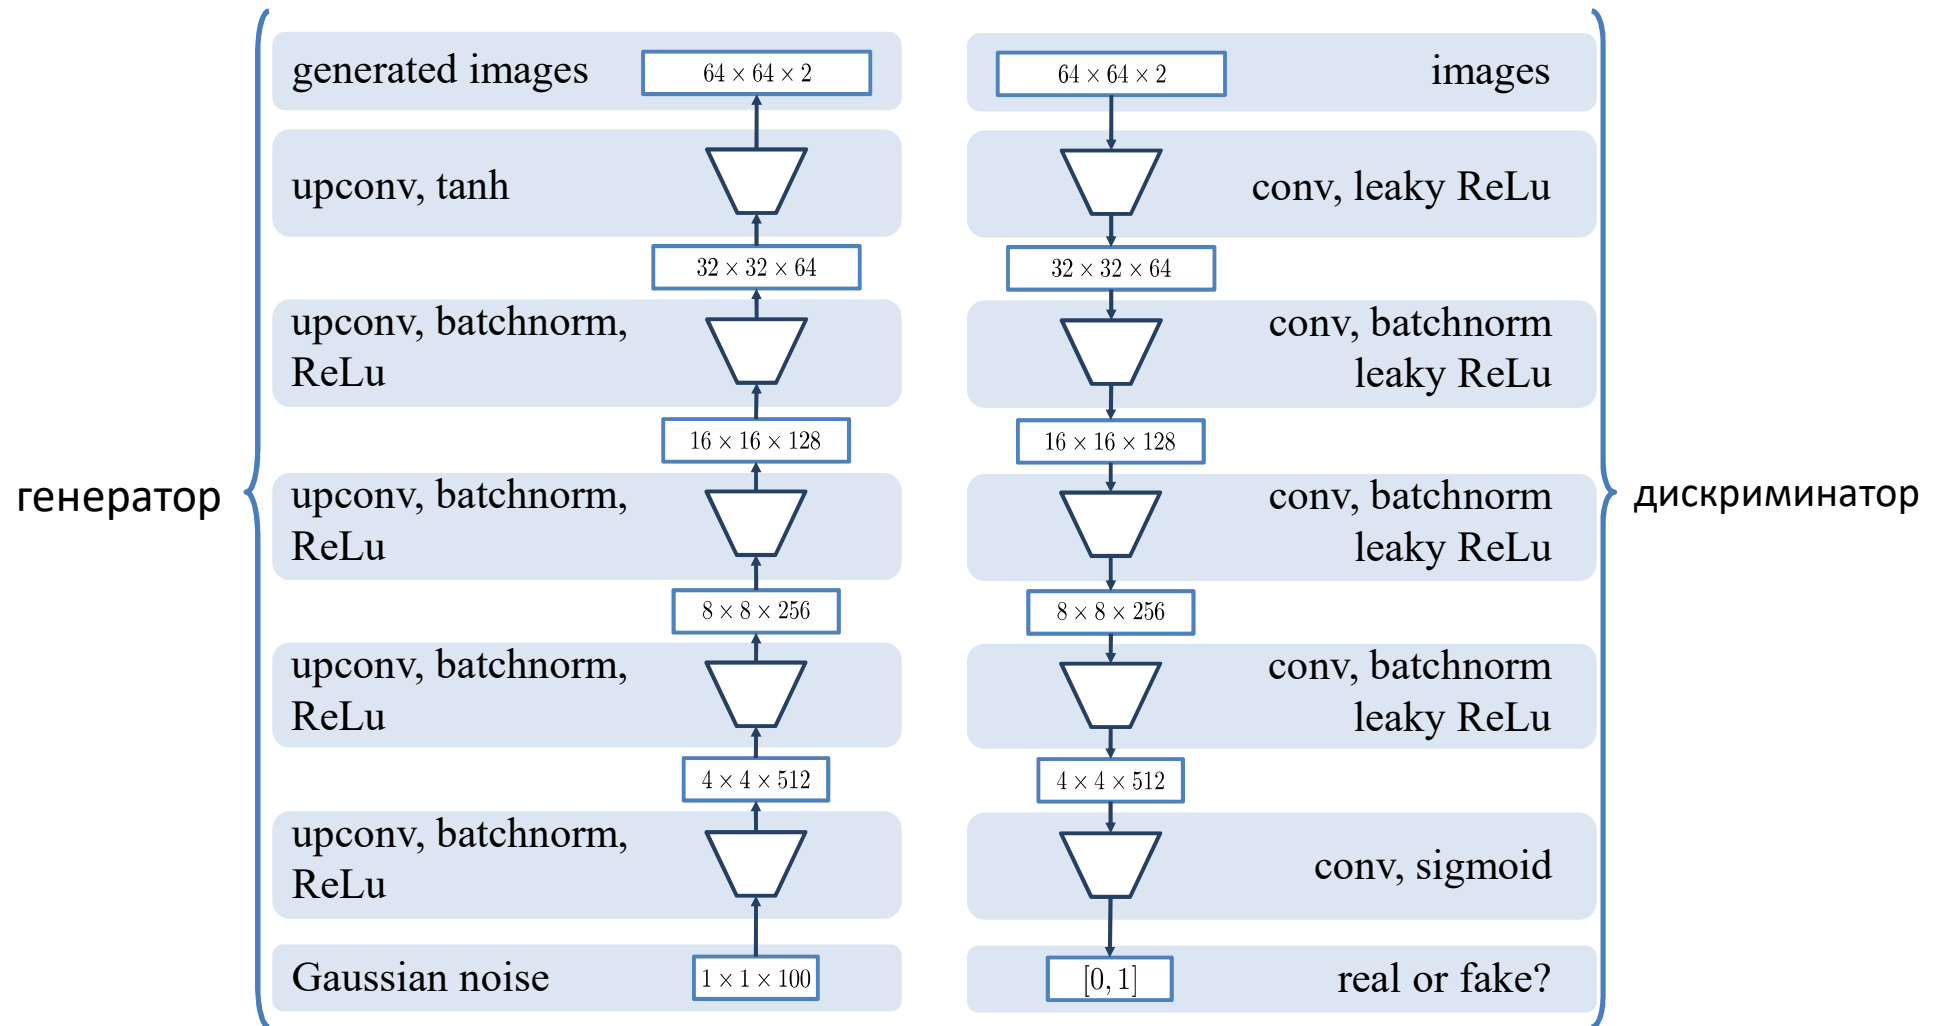
Image credit: Ian Goodfellow

GANs работают?

- Часто, модель сложно заставить работать
- Инженерные практики, которые помогают?
<https://github.com/soumith/ganhacks>
- Много работ по улучшению GAN

Архитектура DCGAN


[Radford et al. 2014]



Что генерируют GANs?

Images from Goodfellow (2016)




- Много хайпа
- Примеры из разных GAN-методов:



Что генерируют GANs?

- Сложно генерировать реалистичные изображения
- Компьютерная графика в принципе может лучше
- Но естественные изображения – сложный объект

Глобальная структура:



Images from Goodfellow (2016)

GANs быстро развиваются

[Karras et al. 2017]


- Фотореалистичные лица



GANs быстро развиваются


[Karras et al. 2017]

- Фотореалистичные лица
- Не все объекты так хорошо



Adversarial функции потерь

- Дискриминатор является дифференцируемой функцией потерь!
- Обучаемой вместе с генератором
- Пример: pix2pix [Isola et al., 2017]



- Используется там, где нет хороших функций потерь
 - Изображения, звук, RL
 - Теперь и для текстов

Заключение

- Adversarial examples – фундаментальный феномен ML
 - Можно ли бороться?
 - Является ли ключом к пониманию сетей?
 - Adversarial для людей
- Domain adaptation – способ получить больше данных с метками
 - Очень важно на практике
- Adversarial функции потерь – способ задавать функции потерь для сложных данных



@teenybiscuit